

面向多轮交互式长编程任务的 记忆自优化

基座: TencentDB-Agent-Memory / MemoryCore v2.0.0-beta.1
公开数据: Memora、MemOps、LongMemEval-V2
实验范围: 公开长对话方法验证, D1-D18
文档版本: 2026-08-24

目录

第一部分 研究报告	1
摘要	1
1 研究背景与问题定义	1
1.1 多轮长任务中的记忆失效	1
1.2 研究问题	1
1.3 演化边界	2
2 系统设计与候选策略	2
2.1 Base: 基座路径	2
2.2 V1: 纠错链固定预算重定向	2
2.3 V2: 代理选择的多因素增强	2
2.4 受控自优化协议	2
2.5 三类证据轨	3
3 数据、指标与实验协议	3
3.1 公开数据与用途	3
3.2 质量与成本指标	3
3.3 Reader 与 Judge	3
3.4 数据边界与复算	3
3.5 实验实现与计算投入	4
4 研究过程与实验结果	4
4.1 V1 与 V2: 条件机制效果和代理反转	4
4.2 D1-D4: 失效证据处理与预算装箱	4
4.2.1 D1 过时值屏蔽	4
4.2.2 D2 查询风险路由	4
4.2.3 D3 删除空位回填	4
4.2.4 D4 有效状态装箱	4
4.3 D5-D6: 显式目标状态与现行策略保护	5
4.3.1 D5 目标键控状态	5
4.3.2 D6 现行策略守卫	5
4.4 D7-D11: 状态变化、过程记忆与证据压缩	5
4.4.1 D7 状态差分	5
4.4.2 D8 效用门与空动作	5
4.4.3 D9 结果门控过程记忆	5
4.4.4 D10 局部验证替换	5
4.4.5 D11 证据保真压缩	5
4.5 D12-D15: 证据可达性与错误前提修复	6
4.5.1 D12 同轨迹外部证据扩展	6
4.5.2 D13 残差反馈补丁	6
4.5.3 D14 前提反驳证据	6
4.5.4 D15 类型化反驳合同	6
4.6 D16: 广覆盖基线与单因素消融	6
4.7 D17: 立场感知代理	7
4.8 D18: 文本纠错检测与自动构链	7
5 方向总账与研究判断	7
6 最终优化策略	8
6.1 风险门控的质量轨	8
6.2 证据保真压缩的效率轨	8
6.3 可拒绝的构链轨	8
7 面向多轮编程数据的迁移设计	8
7.1 Scope 表示	8
7.2 可执行 witness	9

7.3 适配接口	9
7.4 后续验证协议	9
8 证据边界与局限	9
9 相关工作与研究定位	9
10 复现与审阅入口	10
11 结论	10
 第二部分 学术论文（中文译稿）	 11
1 引言	11
2 相关工作与研究定位	12
3 问题定义	12
4 生命周期策略与晋升	13
4.1 Base 与固定预算 V1	13
4.2 上下文增强 V2	13
4.3 分层晋升	13
4.4 运行回退与语义回退	13
5 实验协议	13
5.1 公开数据与适配器	13
5.2 指标与聚合	13
5.3 模型评测	14
5.4 时间顺序与数据使用	14
5.5 实现与调用规模	14
6 D1–D15 研究计划：假设、实验与决策	14
6.1 D1–D4：失效处理与预算约束上下文	14
6.2 D5–D6：显式状态与现行策略保护	15
6.3 D7–D11：状态变化与过程记忆	15
6.4 D12–D13：证据可达性与残差修复	15
6.5 D14–D15：低覆盖条件下的前提反驳	16
6.6 跨方向综合	16
7 条件型 V1/V2 答案实验	16
8 D16：广覆盖基线与单因素消融	17
8.1 设计与完整性	17
8.2 全量结果	17
8.3 V1 的异质效果	17
9 D17：立场能否修复代理指标？	18
10 D18：纯文本纠错构链	18
10.1 协议	18
10.2 结果	18
11 D11：独立效率证据	18
12 讨论	19
12.1 已经获得支持的机制	19
12.2 未通过验证的机制	19
12.3 向编程会话迁移	19
12.4 成本与置信度	19
13 局限	19
14 可复现性与产物	19
15 结论	20

第一部分 研究报告

摘要

本项目研究多轮交互中记忆的更新、失效、检索、组织与压缩问题。在 MemoryCore 基座检索之上，项目实现了可关闭、可回退、容量和时延有界的生命周期旁路，并建立了基于受控反馈的策略提出与晋升协议。策略层根据纠错关系、直接证据、答案质量、遗忘安全和上下文成本更新参数或辅助结构；FTS5、向量检索和基座抽取模型保持不变。

研究首先提出纠错链固定预算重定向策略 V1，并在 50 个已确认出现过时记忆暴露的问题上验证其机制效果。随后提出多因素增强策略 V2，并通过答案评测发现直接检索代理与下游答案发生反转。围绕这一问题，项目依次开展 D1-D18 共 18 个研究方向，覆盖过时证据屏蔽、风险路由、状态投影、过程记忆、证据保真压缩、前提反驳、广覆盖消融、代理校准和文本自动构链。

早期条件实验中，V1 相对 Base 的答案 FAMA 提高 8.09 个百分点。D16 在未按 Base 失败筛选的 200 题上得到 1.42 个百分点的全量增益，其置信区间触及零；92 个含遗忘标准的问题提高 2.96 个百分点，38 个推荐问题提高 7.68 个百分点，62 个记忆问题出现 MPA 下降 1.53 个百分点的伤害信号。V1 因此保留为高遗忘风险条件下的研究基准策略。

V2、四个简单基线及六个单因素增强均未通过预先冻结的质量、成本和不确定性门槛。D11 在 LongMemEval-V2 测试集上将平均注入 token 从 2,796.8 降至 2,213.9，下降 20.84%，12 个可直接评分问题的证据支持度与 Base 相同；该结果作为效率证据保留，答案级非劣性尚未验证。D18 的文本纠错事件检测达到 97.89% 精确率和 79.64% 召回率，但前驱记忆链接精确率仅为 20.05%，未达到自动构链要求。

最终方案采用质量、效率和构链三条独立证据轨。质量轨在 Base 与 V1 之间进行风险门控；效率轨单独验证 D11 的答案非劣性；构链轨对不确定链接执行 abstain。所有候选均须通过答案级、成本、完整性与回退门槛后才能晋升。

1 研究背景与问题定义


1.1 多轮长任务中的记忆失效

MemoryCore 提供 L0 对话、L1 原子记忆、L2 场景和 L3 画像，并支持 FTS5、向量检索、多路融合、抽取与注入。基座能够保存和检索历史信息，但返回条数、候选池、写入条件和注入预算主要由静态配置控制。

多轮编程任务中的事实具有显著的状态依赖性：

- 用户可将 REST 方案更新为 GraphQL；
- 接口、文件或符号可在后续轮次中重命名；
- 方案可被撤销、回滚或替换；
- 分支、commit、worktree 和依赖环境可发生切换；
- 测试结论可能只对某一代码版本成立；
- 已记录的用户约束可被明确取消。

词法或向量相似度只衡量相关性，不能判断事实在当前状态下是否仍然有效。永久删除旧记忆会损失历史来源、纠错链和时间比较能力。因此，本研究将记忆表示为带状态和来源的生命周期对象：



1.2 研究问题

本项目回答四个研究问题：

1. 已知纠错关系时，如何在固定上下文预算内减少过时记忆对答案的污染？
2. 如何使用公开评测或受控反馈更新策略，同时防止直接检索代理晋升答案更差的方案？

3. 状态投影、过程记忆、证据压缩和前提反驳能否改善质量或降低成本？
4. 纠错关系能否从原始长对话文本中自动构造，并达到可用于记忆失效的精度？

1.3 演化边界

策略演化限定在以下范围：

- 更新阈值、跳数、槽位、预算和路由规则；
- 增加有容量上限的纠错关系、状态视图、过程 capsule 或压缩结构；
- 根据冻结反馈决定候选的保留、拒绝或晋升；
- 关闭旁路时恢复 Base；
- 异常、超时、循环、损坏或容量越界时整次调用返回 Base。

本项目不修改 FTS5 和向量检索内核，不重训基座抽取模型，不使用私有编程数据形成公开实验结论。

2 系统设计与候选策略

2.1 Base：基座路径

Base 使用相同的 MemoryCore 数据、SQLite FTS5 / 向量候选、原始排序和注入预算。Base 同时承担对照组、关闭开关后的等价路径和旁路失败时的回退路径。

2.2 V1：纠错链固定预算重定向

V1 的版本标识为 lifecycle-adaptive-v1.0，执行过程如下：

1. 写入侧从公开 Memora 的更新或删除操作元数据构造前驱到后继的关系；
2. 查询侧首先获得完整 Base 候选；
3. Base Top-5 命中已失效前驱时，沿高置信纠错边重定向到当前后继；
4. 去重后从同一 Base 候选池回填，最终条数不超过 5；
5. 置信阈值固定为 0.85，最多一跳，最多 64 次扩展，旁路预算为 10 ms；
6. 关闭、损坏、循环、超时或容量异常时返回字节等价的 Base 结果。

V1 检验已知纠错关系条件下的生命周期管理能力。其前驱关系来自公开结构化操作字段，因此属于结构化真值辅助的管理实验。D18 单独评估从原始文本构造关系的能力。

2.3 V2：代理选择的多因素增强

V2 的版本标识为 lifecycle-contextual-v2.1。候选空间包含 36 个组合：

- 置信阈值 0.85、0.91 或 0.96；
- 最大跳数 1 或 2；
- 根据重定向数量增加 0、1 或 2 个槽位；
- 对历史汇总或比较查询启用或关闭保护。

直接证据代理选择出的组合为阈值 0.96、两跳、两个附加槽位和历史保护。V2 在直接检索指标上优于 V1，答案级评测未通过晋升门槛。

2.4 受控自优化协议

自优化由候选提出和候选晋升两个阶段组成：

公开反馈或受控结果



候选提出：在冻结的参数、规则或辅助结构空间中选取候选



直接门槛：覆盖、证据、token、时延、容量、回退



答案门槛：MPA、FAA、FAMA、置信区间、分模型方向



全部通过 | 任一失败

▼ ▼
 晋升候选 保留现行策略并记录拒绝原因

策略空间、数据、阈值、抽样和决策门槛均在评分前写入版本化 protocol。开发结果只用于提出下一候选，验证或测试失败后不得改子集重新解释为通过。

2.5 三类证据轨

- 质量轨：要求答案 FAMA 改善，同时满足 FAA、MPA、成本、完整性和回退约束。
- 效率轨：要求答案质量在预设非劣界内，并满足 token 或时延降幅。
- 构链轨：要求纠错事件、类型和前驱链接达到各自的精确率、召回率和覆盖门槛。

运行回退只保证旁路故障不会破坏 Base 服务。Base 结果本身仍可能包含过时信息，因此运行安全与语义安全分别报告。

3 数据、指标与实验协议

3.1 公开数据与用途

数据	使用规模	实验用途
Memora	600 问题、27,614 个会话、10 个 persona	V1/V2、D1-D4、D16-D18；当前事实、失效事实与答案遗忘
MemOps	403 对实例、2,558 个操作、2,006 个纵向 probe	D5-D6；显式目标键下的更新、删除与状态管理
LongMemEval-V2 small tier	200 个选定问题、1,870 条轨迹	D7-D15；状态差分、过程记忆、证据组织与压缩

数据读取、事件、来源、反馈、指标和报告均通过适配接口连接，主策略不依赖单一公开数据 schema。

3.2 质量与成本指标

- MPA (Memory Presence Accuracy)：答案覆盖应保留当前事实的比例。
- FAA (Forgetting Absence Accuracy)：答案避免使用已失效事实的比例。
- FAMA：对单个答案计算 $\max(0, \text{MPA} - \lambda \times (1 - \text{FAA}))$ ， λ 为该题遗忘标准占全部标准的比例；先在答案单元内计算，再对两个 reader 单元和冻结问题总体依次求均值。
- 直接证据代理：当前事实可达率减去过时事实暴露惩罚。
- 成本：平均注入 token、注入条数、p50/p95 时延、预算违规和回退次数。

直接证据代理可确定复算，不能识别答案对旧事实的肯定、否定或历史叙述立场，因此仅用于候选筛选。

3.3 Reader 与 Judge

MiniMax-M3 和 DeepSeek-V4-Flash 同时承担答案生成模型 (reader) 和裁判模型 (judge)：

- MiniMax 生成的答案由 DeepSeek 主裁判；
- DeepSeek 生成的答案由 MiniMax 主裁判；
- D16 禁止 self-judgment；
- 无法解析的 verdict 按错误处理；
- 模型、端点、采样、重试和聚合顺序均由协议冻结。

早期双裁判一致率为 96.79%，Cohen's kappa 为 0.899。该结果反映模型间协议一致性，尚未经过人工裁判标定。

3.4 数据边界与复算

- 早期 50 题从 61 个 Base Top-5 已暴露过时值的问题中按 persona 冻结，估计条件机制效果。
- D16 使用两个早期答案面板均未消费的 200 个季度问题，不按策略结果或 Base 失败筛选。
- Memora 全部 600 问题曾用于早期代理分析，D16 属于答案未消费的广覆盖实验，不属于全新外部留出集。
- D16 独立 validator 从 1,894 条原始 verdict 重算 13 个 arm 和 12 个 V1 对比，数值差异为 0。
- D18 预测阶段禁止读取 session_type、operation、operation_details 和评测标签，预测完成后才连接金标准。

3.5 实验实现与计算投入

生命周期 benchmark 当前包含：

- 54 个版本化 protocol JSON；
- 251 个 TypeScript 源文件和测试文件，其中测试文件 50 个；
- 85 个结构化结果文件，包括逐例 JSONL、summary、decision、admission 和 independent validation；
- 关闭、损坏、超时、循环、容量和结构异常的精确回退用例。

可核对的 MiniMax-M3 / DeepSeek-V4-Flash 实验共完成 2,456 次 reader 调用和 3,018 次 judge 调用，合计 5,474 次。D16 单轮使用约 2,805,144 API token。其 2,600 个问题-策略上下文经字节等价复用后，每个 reader 仅生成 947 个唯一答案，reader 调用量相对逐 arm 独立生成下降 63.6%。

4 研究过程与实验结果

4.1 V1 与 V2：条件机制效果和代理反转

早期主实验从 192 个季度遗忘问题中识别出 61 个 Base Top-5 暴露过时值的问题，并按 persona 冻结 50 个样本。该面板含 43 个推荐问题和 7 个记忆问题。

策略	MPA	FAA	FAMA	平均注入 token
Base	0.3855	0.8531	0.3195	144.52
V1	0.4342	0.9369	0.4004	146.76
V2	0.4461	0.8961	0.3961	201.84

V1 相对 Base 的 FAMA 提高 8.09 个百分点，95% persona-cluster CI 为 [5.17, 12.59] 个百分点；FAA 提高 8.38 个百分点，token 增加 1.55%。该结果支持已知纠错关系和已发生过时暴露条件下的重定向机制。

V2 相对 V1 的 FAA 下降 4.08 个百分点，FAMA 下降 0.43 个百分点，token 增加 37.53%。V2 在直接代理上的优势未转化为答案收益，晋升器保留 V1。该实验确立了后续研究的决策原则：代理用于提出候选，答案与成本用于晋升候选。

4.2 D1-D4：失效证据处理与预算装箱

4.2.1 D1 过时值屏蔽

理论假设：V1 保留失效前驱的文本可能继续暴露旧值；遮蔽旧值可提高 FAA。

实验过程：保持 V1 的候选身份、顺序和条数不变，只对注入文本中的旧值执行遮蔽。在冻结答案面板上比较上下文暴露、MPA、FAA 和 FAMA。

结果与判断：过时值暴露率由 74% 降至 8%，FAA 上升；MPA 下降 2.02 个百分点且置信区间为负。旧值同时承担实体锚点和语义定位作用。D1 未通过答案安全门槛。

4.2.2 D2 查询风险路由

理论假设：D1 对部分查询有利，对需要实体锚点的查询有害；运行时风险特征可在 V1 与 D1 之间选择。

实验过程：使用交叉拟合规则，依据查询和上下文的表面特征预测屏蔽风险，禁止同一问题同时参与规则拟合和评估。

结果与判断：FAA 提高 2.83 个百分点，MPA 下降 1.15 个百分点；DeepSeek reader 的 FAMA 方向仍为负。表面特征不能稳定识别锚点依赖，D2 被拒绝。

4.2.3 D3 删除空位回填

理论假设：删除事件形成 tombstone 后会占用 Top-k；从同一 Base 候选池回填空位可恢复有效证据。

实验过程：不扩大 Base 候选边界，只在删除形成空位时继续扫描同一候选池并保持固定返回条数。

结果与判断：直接代理提高 1.40 个百分点，低于预设 2 个百分点门槛；token 增加 2.89%。D3 未达到幅度和成本要求。

4.2.4 D4 有效状态装箱

理论假设：固定条数不能保证固定 token 成本；在 V1 token 上限内联合控制条数和预算可提高当前状态密度。

实验过程：在 9 个条数-token 组合中使用开发反馈选择一个候选，并在新的 50 题面板上固定评估。

结果与判断：FAMA 提高 1.16 个百分点，token 降低 3.27%；95% CI 为 [-0.14, 2.90] 个百分点。正向点估计未达到不确定性门槛，D4 作为近失方案拒绝。

4.3 D5-D6：显式目标状态与现行策略保护

4.3.1 D5 目标键控状态

理论假设：按旧值字符串寻找失效对象存在实体歧义；显式 operation target 能形成更准确的当前状态视图。

实验过程：在 MemOps 中按目标键执行 Update、Delete 和 No-op 状态投影，并与 V1 的值匹配路径比较。开发、验证和未触碰测试按协议分离。

结果与判断：测试 state-FAMA 提高 6.46 个百分点，95% CI 为 [-2.40, 15.10] 个百分点；4 个 Update 问题受损。显式 target 改善状态语义，但独立投影会丢失 V1 已找回的后继证据，D5 未通过测试门槛。

4.3.2 D6 现行策略守卫

理论假设：D5 仅在保留 V1 已有当前或未知证据、且不引入旧证据时启用，可减少组合伤害。

实验过程：增加支配关系守卫；候选必须覆盖现行策略的全部受保护项，未满足时返回 V1。

结果与判断：已消费数据的后验审计中，state-FAMA 提高 6.11 个百分点，28 个问题改善、0 个问题受损。该规则形成可行性证据，因使用已消费数据提出，未晋升，需在新数据上确认。

4.4 D7-D11：状态变化、过程记忆与证据压缩

4.4.1 D7 状态差分

理论假设：原始页面或工具状态包含大量静态信息；pre/action/post 差分能突出任务推进所需变化。

实验过程：从 accessibility tree 构造状态变化单元，与 Base FTS5 并行检索；开发集选择固定策略后，在验证集保持参数不变。

结果与判断：开发集直接支持度提高 8.13 个百分点；验证集下降 6.67 个百分点，token 增加 3.50%。差分表示未跨数据迁移，D7 被拒绝。

4.4.2 D8 效用门与空动作

理论假设：D7 的变化单元质量不均；从已消费数据学习效用并允许 null action 可避免低效替换。

实验过程：对候选变化单元设置效用门，未达到阈值时不改变 Base；在未触碰测试上评估。

结果与判断：token 下降 2.92%，直接支持度与 Base 完全相同，改善问题数为 0。D8 未产生质量收益，压缩信号保留给后续研究。

4.4.3 D9 结果门控过程记忆

理论假设：成功轨迹包含可复用过程，失败轨迹应降低写入或检索优先级。

实验过程：将结果标签作为过程 capsule 的准入条件，并设置不读取结果标签的消融。开发选择后在验证集固定评估。

结果与判断：开发集中结果无关消融优于结果门控版本；验证集直接支持度下降 11.11 个百分点。整轨迹成败对局部步骤提供的信用过粗，D9 被拒绝。

4.4.4 D10 局部验证替换

理论假设：局部状态进展比整轨迹结果更适合作为步骤级反馈；仅替换同轨迹 Base 项可控制污染。

实验过程：依据局部状态变化构造绑定安全的过程骨架，在固定预算内替换同轨迹候选。

结果与判断：token 下降 33.55%，但一个问题中含 priority 正确答案的 StaticText 正文被移除；局部反馈未产生支持度提升。过程骨架未保留完整语义证据，D10 因安全失败被拒绝。

4.4.5 D11 证据保真压缩

理论假设：过程压缩只有在保留被替换 Base 项的全部可界定语义叶子、顺序、来源和无关项时才具备安全性。

实验过程：D11 对同轨迹项生成有界 capsule；语义叶子、来源、顺序、条数、token certificate 或 fallback 任一检查失败时返回 Base。LongMemEval-V2 未触碰测试包含 30 个问题，其中 12 个可直接计算答案原子支持度。

结果与判断：19 个替换被接受；平均 token 从 2,796.8 降至 2,213.9，下降 20.84%。12 个直接问题的

Base 与 D11 支持度均为 0.2083, 0 改善、12 相同、0 受损。原质量协议要求支持度改善, 因此质量晋升被拒绝; 该结果作为效率候选保留, 需补充答案级非劣实验。

4.5 D12-D15: 证据可达性与错误前提修复

4.5.1 D12 同轨迹外部证据扩展

理论假设: D11 只能压缩 Base 已检索证据; 从 Base 前缀之外补充一条同轨迹证据可能恢复缺失答案原子。

实验过程: 保持 Base 预算, 从同轨迹 Top-40 中最多加入一条 Base 未包含的候选, 不读取答案, 不尝试第二候选。

结果与判断: 开发集直接支持度相对 Base 下降 3.33 个百分点, 5 个问题受损。额外证据产生挤占或污染, D12 在开发阶段停止。

4.5.2 D13 残差反馈补丁

理论假设: D12 的扩展只应作用于历史上出现明确缺失签名的问题。

实验过程: 使用已消费问题提取失败签名, 仅对匹配项执行 D12 扩展, 其余返回 Base。

结果与判断: 23 个可直接评分问题全部与 Base 相同, token 增加 0.99%。规则被触发未带来新增答案证据, D13 被拒绝。

4.5.3 D14 前提反驳证据

理论假设: 部分记忆错误表现为查询包含已失效前提; 检索明确反驳证据可阻止错误前提进入答案。

实验过程: 在 33 个 premise 问题和 25 个控制问题上检测反驳触发, 仅对变化上下文调用 reader。

结果与判断: premise 问题触发 2 个, 控制问题误触发 0 个; 四个变化 reader 单元均与 Base 相同。D14 的精度较高、覆盖较低, 未产生答案收益。

4.5.4 D15 类型化反驳合同

理论假设: 将候选渲染为 premise、refutation、witness 和 scope 四类字段, 可提高模型对反驳证据的利用率。

实验过程: 先在 D14 已消费的两个触发问题上进行设计审计, 再冻结 renderer, 在 23 个新 premise 问题和 20 个控制问题上先测触发覆盖; 覆盖门槛通过后才允许答案调用。

结果与判断: 设计审计的 4 个 reader 配对中 3 个改善; 新验证集 43 个问题全部未触发。D15 因验证覆盖率零停止, 未进入答案调用。该拒绝与模型服务余额或评测器故障无关。

4.6 D16: 广覆盖基线与单因素消融

外部审阅指出早期 50 题经过 Base 过时暴露条件筛选、简单基线不足、V2 同时改变多个因素、代理与答案关系未系统检验。D16 使用此前两个答案面板均未消费的全部 200 个季度问题, 包含 100 个 reasoning、62 个 remembering 和 38 个 recommending 问题; 92 个问题含遗忘标准, 仅 6 个问题出现 Base 过时暴露。

D16 设置 13 个 arm: Base、V1、tombstone refill、latest-write-wins、recency Top-5、显式 superseded 渲染、两跳、一个附加槽位、两个附加槽位、阈值 0.91、阈值 0.96、历史保护和完整 V2。

策略	MPA	FAA	FAMA	相对 V1 FAMA, 95% CI	token	决策
Base	0.1500	0.9780	0.1428	-1.42 点 [-3.08, +0.005]	134.19	对照
V1	0.1620	0.9881	0.1570	-	133.16	条件基准
tombstone refill	0.1601	0.9838	0.1533	-0.37 点 [-1.49, +0.70]	133.39	拒绝
latest-write-wins	0.1598	0.9880	0.1543	-0.27 点 [-0.94, +0.39]	135.03	拒绝
recency Top-5	0.1453	0.9821	0.1393	-1.76 点 [-4.03, +0.57]	118.97	质量拒绝
superseded 渲染	0.1559	0.9849	0.1497	-0.73 点 [-2.30, +0.80]	146.99	拒绝
V1 + 两跳	0.1588	0.9879	0.1536	-0.34 点 [-0.86, 0]	134.42	拒绝
V1 + 1 槽	0.1670	0.9862	0.1609	+0.39 点 [-0.68, +1.44]	148.66	成本/CI 拒绝
V1 + 2 槽	0.1740	0.9831	0.1663	+0.93 点 [-0.27, +2.27]	160.04	成本/CI 拒绝
V1 阈值 0.91	0.1616	0.9889	0.1565	-0.04 点 [-0.13, 0]	133.23	拒绝
V1 阈值 0.96	0.1656	0.9881	0.1600	+0.30 点 [-0.10, +0.83]	133.56	近失
V1 + 历史保护	0.1595	0.9881	0.1545	-0.25 点 [-1.00, +0.50]	134.14	拒绝
V2	0.1680	0.9831	0.1591	+0.21 点 [-0.73, +1.08]	147.99	拒绝

没有候选策略同时通过 FAMA 幅度、置信区间、FAA、MPA、token 和完整性门槛。附加槽位提高 MPA 和 FAMA 点估计，同时降低 FAA 并增加 11.64%–20.19% token。阈值 0.96 形成低成本近失结果，其置信区间仍跨零。

V1 相对 Base 的分层结果如下：

冻结分层	n	FAMA 差值	判断
全部 D16	200	+1.42 点, CI [-0.005, +3.08]	正向, 未达到全量确认
含遗忘标准	92	+2.96 点, CI [+0.74, +5.49]	统计支持
Base 暴露旧值	6	+39.19 点	机制命中收益大, 样本和 cluster 很少
推荐问题	38	+7.68 点, CI [+2.03, +13.95]	明显正向
记忆问题	62	-0.95 点; MPA -1.53 点且 CI 为负	存在伤害信号
推理问题	100	+0.50 点, CI 跨零	未确认收益

早期 50 题集中于推荐任务和 Base 过时暴露, D16 说明 8.09 个百分点属于条件效果。任务标签只用于解释异质性, 不能直接作为线上路由特征。

4.7 D17: 立场感知代理

理论假设: 旧代理对任何过时值出现都施加相同惩罚, 未区分肯定、否定和历史叙述。D17 将三类暴露权重冻结为 1.0、0.25 和 0.1, 并比较 13 个 D16 策略的代理排序与答案排序。

与答案 FAMA 的 Kendall tau-b 由 0.5290 增至 0.5385, 增量 0.0094, 低于预设 0.10 门槛; 相对 V1 的方向判断维持 8/12 一致。D17 未形成可替代答案门槛的代理。

4.8 D18: 文本纠错检测与自动构链

D18 的运行时输入仅包含 session id、persona、共享对话文本和同 persona 最多 512 条历史文本。季度历史按 persona 划分为 4/3/3 个开发、验证和测试 persona。测试集包含 5,954 个 session 和 1,223 个 gold 失效事件。

指标	literal remove/delete	cue-only	高置信 cue + link
事件精确率	100.00%	97.81%	97.89%
事件召回率	15.62%	80.29%	79.64%
事件 F1	27.02%	88.19%	87.83%
类型准确率	100.00%	82.28%	82.34%
前驱链接精确率	—	—	20.05%
前驱链接召回率	—	—	16.18%
至少一条正确链接	—	—	45.38%
p95 时延	—	—	5.51 ms

事件检测通过精确率和召回率门槛; 前驱链接精确率、至少一条正确链接率和类型准确率未通过。词面共享不能可靠判定被失效的实体、字段或状态。V1 的答案结果据此限定为结构化纠错图已知条件下的管理证据。

5 方向总账与研究判断

ID	研究对象	数据阶段	最终状态	主要证据
V1	固定预算纠错链重定向	条件面板 + D16	条件保留	高遗忘风险切片有效; 记忆切片有伤害信号
V2	多因素组合增强	条件面板 + D16	拒绝	FAA、成本和不确定性门槛失败
D1	过时值屏蔽	答案面板	拒绝	降低暴露, 同时损伤 MPA
D2	查询风险路由	交叉拟合答案面板	拒绝	FAA 增益伴随 MPA 和 reader 方向失败
D3	删除空位回填	直接代理	拒绝	幅度低于门槛且 token 上升
D4	有效状态装箱	新答案面板	近失、拒绝	正向点估计, CI 跨零
D5	目标键控状态	MemOps 测试	拒绝	target 有效, 存在 4 个受损 Update
D6	现行策略守卫	已消费后验审计	可行性证据	28 改善、0 受损, 需新验证
D7	状态差分	开发/验证	拒绝	开发增益在验证反转
D8	效用门	未触碰测试	质量拒绝	token 小幅下降, 质量无变化
D9	结果门控过程记忆	开发/验证	拒绝	整轨迹结果信用过粗

ID	研究对象	数据阶段	最终状态	主要证据
D10	局部过程替换	验证	安全拒绝	压缩同时丢失关键正文证据
D11	证据保真压缩	未触碰测试	保留效率证据	token -20.84%，直接支持度不变
D12	同轨迹外部扩展	开发	拒绝	支持度下降，5 个受损
D13	残差补丁	开发	拒绝	质量无变化，token 增加
D14	前提反驳	premise/control	拒绝	低覆盖且答案无变化
D15	类型化反驳	设计/新验证	拒绝	设计样例改善，新验证零触发
D16	广覆盖与单因素消融	200 题答案面板	完成	识别 V1 异质效果，所有候选策略未晋升
D17	立场感知代理	D16 13 策略	拒绝	排序相关性增量 0.0094
D18	文本纠错与构链	persona-disjoint 测试	拒绝构链	事件检测有效，链接精确率 20.05%

这些实验形成四项机制判断：

1. 失效处理需要保留实体锚点和来源，单纯删除旧值会损伤当前事实恢复。
2. 轨迹级成功或失败不适合作为步骤记忆的充分监督，语义叶子和可执行证据必须保留。
3. 更多槽位、更多跳数和更高直接代理均可能降低遗忘安全或增加成本。
4. 纠错事件识别与前驱对象链接应分别评测；前者通过不能替代后者。

6 最终优化策略

6.1 风险门控的质量轨

1. 所有查询首先生成完整 Base 结果。
2. 上游提供高置信、可定位、带来源的纠错关系时，V1 才具备运行条件。
3. 运行时风险路由应使用可观测的失效证据、scope 一致性和查询意图；D16 的 benchmark 任务标签仅用于分析。
4. 当前状态或遗忘风险查询可进入 V1；历史回顾、纯记忆和关系不确定查询保留 Base 或受保护路径。
5. 新阈值、跳数、槽位和渲染候选须经过冻结答案门槛后才能替换现行策略。

6.2 证据保真压缩的效率轨

D11 使用独立晋升协议：

- 预先声明答案 FAMA、MPA 和 FAA 的非劣界；
- 预先声明最低 token 降幅；
- 保留全部语义叶子、顺序、来源和 Base 无关项；
- 约束 selection 与总查询 p95 时延；
- 关闭、损坏、超时或证书失败时返回 Base。

完成新数据上的答案非劣验证后，D11 才具备正式效率晋升条件。

6.3 可拒绝的构链轨

- 显式 remove X、from X to Y、唯一 target id 和结构化工具事件可提出高置信候选；
- 实体、字段或 scope 无法唯一确定时输出 unknown，不修改旧记忆状态；
- 任务失败和弱纠错 cue 只产生候选，不直接执行永久失效；
- Git、测试、用户确认和结构化工具结果可作为独立 witness；
- 构链精度、覆盖、类型和误失效代价分别评估。

7 面向多轮编程数据的迁移设计

7.1 Scope 表示

编程记忆的有效性键应至少包含：

```
(repository,
branch,
base_commit,
worktree_fingerprint,
toolchain_environment,
task_phase,
```

```
entity_file_symbol,
claim_type)
```

每条记忆使用 active、superseded 和 unknown 三值状态。scope 不匹配或证据不足时进入 unknown，避免跨分支、跨环境失效。

7.2 可执行 witness

编程记忆可记录以下支持信息：

- test command 与 exit code；
- commit、文件 hash 和工作树状态；
- 文件、符号、接口和依赖版本；
- 产生结论的工具调用与时间；
- 用户显式确认、撤销或方案替换。

witness 失效时降低置信或转为 unknown；明确 rename、revert、后继事实或用户纠错可形成 superseded 候选。

7.3 适配接口

内部数据接入仅需实现：

- SessionAdapter：会话、轮次、工具调用和任务边界；
- ScopeAdapter：repo、branch、commit、worktree 和环境；
- EventAdapter：更新、删除、撤销、重命名和回滚候选；
- EvidenceAdapter：应保留事实、应失效事实、来源和 witness；
- MetricAdapter：直接记忆效果、误删代价、答案质量和任务结果；
- ReportAdapter：基座/候选模式、k、fallback、信号、耗时和结构化结果。

生命周期控制器、晋升器和回退逻辑保持不变。

7.4 后续验证协议

RepoDriftBench 可将一次编程会话切分为写入、状态变化、查询和注入四类事件，并记录：

- 更新前后约束与 scope；
- 应保留和应失效的记忆；
- 可执行 witness；
- Base 与 lifecycle 注入差异；
- 计划、编辑文件、测试结果和最终 patch 的污染差异。

该协议能够同时测量记忆直接效果、下游任务结果和误失效代价。

8 证据边界与局限

- 公开实验验证生命周期方法，未验证真实多轮编程任务的 pass@1 或任务完成率。
- V1 的结构化前驱关系来自 Memora 发布操作字段；D18 尚未支持可靠自动构链。
- D16 扩大了答案面板并减少条件选择偏差，全部 Memora 问题仍曾参与早期代理研究。
- D16 的分层结果用于解释异质性，尚未形成经过新数据确认的运行时路由器。
- MiniMax-M3 与 DeepSeek-V4-Flash 的交叉裁判降低自评偏差，模型间一致性尚未由人工金标准校准。
- D11 只有 12 个可直接评分问题，且未进行生成答案非劣实验。
- Base 精确回退保证运行可用性，不保证返回事实的时态正确性。
- D1-D18 属于连续科学探索；最终部署结论需要全新公开集或内部编程数据确认。

9 相关工作与研究定位

- [Memora](#) 将 remembering、reasoning、recommending 和 forgetting-aware FAMA 统一到周/月级长对话评测。本项目使用其当前与失效标准评估生命周期策略。
- [MemoryAgentBench](#) 将准确检索、测试时学习、长程理解和选择性遗忘区分为不同能力，支持多指标评测设计。
- [MEMPROBE](#) 直接审计交互后保留的 memory artifact，支持将记忆质量与任务完成结果分别测量。

- Graphiti 与 Zep 使用有效时间和来源表示时态事实。本项目采用 MemoryCore 上的有界旁路实现。
- SWE-MeM 研究代码 Agent 的自适应压缩时机和粒度；D11 验证更窄的证据保真压缩问题。
- Structurally Aligned Subtask-Level Memory 指出整实例记忆存在粒度错配；D9–D11 观察到整轨迹结果标签对局部步骤信用不足。
- ToM-SWE 研究软件工程交互中的持续用户目标和约束，说明编程迁移需要显式状态与 scope。

本研究位于既有检索引擎与端到端编程 Agent 之间，研究反馈如何提出生命周期候选、下游答案如何执行策略晋升，以及质量、效率和构链证据如何隔离。

10 复现与审阅入口

- D1–D18 结构化方向账本
- D16 广覆盖实验摘要
- D16 原始答案与裁判记录
- D16 独立重算
- D17 代理排序结果
- D18 文本检测与构链结果
- D11 测试结果
- D1–D11 机器账本
- D1–D18 研究路线
- 完整结果摘要
- 英文论文源文件

11 结论

本项目在 MemoryCore 基座上实现了有界生命周期旁路、策略提出与晋升协议、公开数据适配层、结构化实验输出和精确回退机制，并完成 V1/V2 与 D1–D18 的连续实验。

V1 在 Base 已暴露过时记忆和含遗忘标准的样本上获得答案收益；广覆盖实验未支持全流量默认启用，并发现纯记忆任务的 MPA 伤害信号。V2、简单时序基线、多跳、附加槽位、状态投影、过程记忆、前提反驳和立场代理的当前实现均未达到冻结晋升门槛。D11 形成 token 降低 20.84% 且直接证据支持度不变的效率结果。D18 通过纠错事件检测门槛，未通过前驱链接门槛。

最终策略保留 Base，V1 仅在高置信、scope 一致的纠错关系和经新数据验证的风险条件下进入质量轨；D11 进入独立效率非劣验证；自动构链对不确定对象执行 abstain。后续实验应集中于 repo、branch、commit、worktree 和 environment 范围内的可执行 witness 与精确失效链接。

第二部分 学术论文（中文译稿）

当更好的检索带来更差的答案： 跨十八个研究方向的下游门控生命周期记忆

本部分为英文论文的完整中文译稿；实验数据、公式、表格、引用键和参考文献保持一致。

摘要

长期运行的编程 Agent 既要保留既有决策，也要避免继续使用已经重命名、纠正、回滚、删除，或因分支和环境变化而失效的约束。静态检索可能返回过时陈述；直接删除又会丢失来源。本文在既有记忆引擎之上研究一个更窄的问题：如何让有界生命周期旁路根据反馈提出策略更新，同时阻止检索代理指标将答案表现更差的策略晋升？

我们在 MemoryCore 中实现了基于纠错关系的前驱-后继重定向、固定成本回退、协议版本化策略搜索、简单时序基线、单因素消融、代理对齐诊断和纯文本纠错检测。公开实验使用 Memora、MemOps 和 LongMemEval-V2 作为方法验证载体，不用于推断私有编程流量上的业务效果。在一个冻结的、以过时 Base 暴露为条件的 50 题面板上，固定预算 V1 将答案 FAMA 提高 8.09 个百分点（95% persona 聚类置信区间：5.17–12.59）。随后对 200 个未按 Base 失败筛选的问题进行普查，全量增益缩小为 1.42 个百分点（区间：-0.005–3.08 个百分点）；其中 92 个含遗忘标准的问题获得经确认的 2.96 个百分点增益，纯记忆任务则出现 MPA 伤害信号。因此，V1 是条件型现行策略，不能作为全流量默认策略。

由代理选出的 V2 在条件面板上改善了直接检索，却相对 V1 损失 4.08 个 FAA 百分点，并多使用 37.5% 的上下文。在广覆盖面板上，四个简单基线、六个独立 V2 因素和完整 V2 均未通过冻结晋升门槛。立场感知代理与答案 FAMA 的 Kendall τ_b 仅由 0.529 提升至 0.538。纯文本检测器在 persona 隔离的测试历史上识别失效 session 的精确率为 97.89%、召回率为 79.64%，但前驱链接精确率只有 20.05%，因此无法支持端到端纠错链结论。作为独立结果，证据保真压缩在校验值冻结的 LongMemEval-V2 测试上减少 20.84% 的注入 token，直接答案原子支持度保持不变；但尚未建立答案级非劣性。

十八个研究方向共同支持三项证据边界：低成本反馈可以提出策略，下游答案与成本负责晋升策略，不确定纠错链接必须拒答。精确运行回退是必要条件，但不等于语义安全。代码和适配接口可迁移至编程会话；以仓库、分支、commit 和环境为范围的有效性仍属于后续工作。

1 引言

交互式软件任务会持续变化。用户可能将 REST 替换为 GraphQL、重命名接口、废止测试预期、回滚设计、切换分支或更换工具链。当记忆系统同时检索到旧约束和当前约束时，它可能以很高置信度重新引入已经被拒绝的决策。词法和向量相关性不能推出当前有效性。永久删除历史同样不可取：来源会丢失，历史问题更难回答，解释当前状态的纠错本身也可能无法访问。

长期记忆系统已经研究了层级、抽取、整合、图结构和上下文管理 [8, 15, 1, 9]。现有基准揭示了时序推理、状态更新和选择性遗忘方面的失败 [6, 14, 4]。Memora 通过 Memory Presence Accuracy (MPA)、Forgetting Absence Accuracy (FAA) 和 Forgetting-Aware Memory Accuracy (FAMA) 显式区分应保留记忆与已失效记忆 [13]。MEMPROBE 进一步指出，任务完成能力与记忆所保留的可恢复状态是两种不同能力 [5]。

本文研究 MemoryCore 之上的生命周期控制。MemoryCore 是一个开源分层记忆服务，提供对话检索、原子记忆、场景、画像、HTTP 访问、SQLite FTS5 和向量检索 [12]。我们不重训抽取器，也不替换基座索引；有界旁路记录纠错关系、变换固定候选列表，并在关闭或失败时返回精确的基座调用结果。

核心工程风险来自不完整代理指标驱动的优化。直接审计可能显示当前证据更多、过时证据更少，但上下文措辞、实体锚点、附加槽位或解码行为的变化仍可能使最终答案变差。因此，我们将候选提出器与晋升门槛分开。提出器可使用低成本反馈；晋升必须同时满足冻结的下游质量、遗忘安全、成本、不确定性和完整性检查。

本文贡献如下：

- 实现一个基于纠错关系、固定预算的生命周期旁路，并约束遍历、容量、时延、关闭开关和整次调用 Base 回退；
- 建立提出-晋升协议，在答案生成后拒绝直接代理赢家，并将质量晋升与效率晋升分开；

- 完成一个包含 200 个问题、13 个 arm 的广覆盖答案实验，加入强简单基线和单因素消融，使用 MiniMax-M3 与 DeepSeek-V4-Flash 进行交叉且无自评的评测；
- 建立包含十八个方向的研究账本，保留屏蔽、路由、状态投影、状态变化记忆、过程记忆、证据扩展、结构化反驳、代理设计和自动构链中的负结果；
- 完成纯文本、persona 隔离的纠错构链审计，证明事件检测可以迁移，而前驱链接不能；
- 给出独立的证据保真压缩结果，并明确仓库、分支、commit、worktree 和环境范围内编程记忆的迁移边界。

本文结论具有明确边界：当过时记忆已经出现且纠错关系已知时，纠错链管理能够产生收益；现有证据不支持对全部流量启用 V1，不验证私有编程任务，也没有解决端到端纠错链接问题。

2 相关工作与研究定位

长期 Agent 记忆。 MemGPT 将上下文管理视为类似虚拟内存的层级系统 [8]。Mem0 抽取并整合持久信息，A-MEM 构建持续演化的关联笔记网络 [1, 15]。Zep 及其开源 Graphiti 引擎为演化事实附加有效时间窗口和来源 [9, 19]。本文机制的范围更窄：它增强现有检索器，并对每个查询时动作施加明确约束。

超越召回率的评测。 LoCoMo 和 LongMemEval 揭示了长 session 中的时序与更新失败 [6, 14]。MemoryAgentBench 将准确检索、测试时学习、长程理解和选择性遗忘定义为不同能力 [4]。Memora 在周级至月级时间跨度上评估记忆、推理和推荐，并惩罚失效记忆复用 [13]。MEMPROBE 直接审计记忆产物，发现辅助任务表现趋于饱和时，状态恢复仍处于中等水平 [5]。这些工作支持本文将直接记忆证据与答案级使用分开评测。

反馈与自优化。 Reflexion 使用语言反馈更新 Agent 行为 [11]。Memory-R1 学习 add/update/delete/no-op 记忆操作，SelfMem 根据环境反馈改进记忆策略，DeferMem 学习查询时证据选择 [16, 17, 18]。本文不重现这些训练过程，重点是为已有记忆存储定义可审阅的有界策略空间和保护现行策略的晋升协议。

代码 Agent 记忆。 SWE-MeM 允许 Agent 决定何时、如何压缩长软件工程轨迹，并联合优化记忆与问题解决 [3]。结构对齐的子任务记忆研究指出，整体实例记忆存在粒度错配 [10]。ToM-SWE 在有状态软件工程交互中持续维护用户目标与约束 [20]。这些研究说明记忆与代码 Agent 密切相关，但没有消除本文的公开数据限制：Memora 不包含仓库、分支、commit、worktree 或工具链标签。因此，本文将编程迁移表述为带 scope 的适配设计，不将其作为实证结果。

3 问题定义

设未修改的基座检索器返回排序候选池

$$B(q) = (m_1, \dots, m_K),$$

其注入前缀记为 $B_k(q)$ 。一个生命周期事件定义为

$$e = (t_e, \kappa_e, c_e, V_e^-, S_e, s_e),$$

其中， t_e 表示顺序， $\kappa_e \in \{\text{update}, \text{delete}\}$ 表示事件类型， c_e 表示置信度， V_e^- 包含已失效值， S_e 包含后继记忆标识， s_e 记录来源。当某条前驱记忆早于事件且包含已失效值时，系统为其建立指向 S_e 的边。

策略 π_θ 将 $B(q)$ 与有界生命周期账本映射为注入列表。策略必须满足容量、时延、返回条数和完整性约束。旁路被关闭、结构损坏、出现循环、容量超限或超时，整次调用返回 $B_k(q)$ ，不返回部分变换结果。

本文区分三类目标：

1. **质量**：在不违反遗忘安全或成本约束的前提下改善下游答案；
2. **效率**：在保持冻结质量不变量的同时降低上下文成本；
3. **构链**：在不使用 oracle 操作元数据的条件下推断生命周期事件和前驱链接。

评分后禁止改变目标。特别地，按质量改善目标冻结的候选不能因为节省 token 而被追溯晋升。

4 生命周期策略与晋升

4.1 Base 与固定预算 V1

Base 是未修改的 MemoryCore L0 检索与注入路径。研究现行策略 V1 对已失效的基座候选沿最新合格纠错边进行重定向，删除重复语义叶子，并从同一基座候选池回填。固定参数为

$$\tau = 0.85, \quad H = 1, \quad E = 64, \quad k = 5, \quad T = 10 \text{ ms},$$

分别对应置信阈值、跳数、扩展容量、输出条数和旁路时延。账本可将前驱直接链接到最新合格纠错，因此查询时的一跳可以代表更长的更新历史。

Memora 实现使用公开的写入时操作字段构造 V1 边。这些字段不包含评测答案，但使管理实验在事件类型和失效值方面具有准 oracle 性质。第 10 节单独评估纯文本构造器。

4.2 上下文增强 V2

V2 候选空间改变置信阈值 $\tau \in \{.85, .91, .96\}$ 、跳数 $H \in \{1, 2\}$ 、依赖重定向数量的附加槽位 $s \in \{0, 1, 2\}$ ，以及历史汇总保护 $p \in \{0, 1\}$ 。36 策略提出器在周级/月级反馈上优化直接遗忘感知代理，并选择 $\tau = .96$ 、 $H = 2$ 、 $s = 2$ 和 $p = 1$ 。容量仍为 64，时延仍为 10 ms。V2 只是一项候选提议，不会自动进入部署。

4.3 分层晋升

对现行策略 θ_I 、候选策略 θ_C 和冻结检查 $g_1, \dots, g_J$ ，研究策略定义为

$$\theta^* = \begin{cases} \theta_C, & \bigwedge_{j=1}^J g_j = 1, \\ \theta_I, & \text{otherwise.} \end{cases}$$

低成本可行性检查覆盖直接证据、受保护切片伤害、上下文成本、时延、容量、关闭等价性和强制失败。只有通过准入的候选才进入答案生成。答案晋升检查 FAMA 幅度与不确定性、FAA、MPA、分 reader 方向和成本。每项失败检查均写入日志。

该机制在有界策略空间内实现自优化：受控反馈改变候选参数或辅助规则，冻结的下游反馈决定系统状态是否更新。它不涉及无约束自修改。

4.4 运行回退与语义回退

精确 Base 回退提供运行安全：损坏的旁路不会破坏基座服务。它不提供语义安全，因为 Base 仍可能检索到过时信息。本文充分测试精确回退，但不将其解释为答案正确性。

5 实验协议

5.1 公开数据与适配器

Memora 修订版 a6493188efc836d6511ed5e4163fe3ba87da30ff 包含 600 个问题、27,614 个 session 文件、10 个 persona，以及周级、月级和季度时间跨度。数据清单 SHA-256 为 dfc82711...331bfc。只有共享记忆轮次进入 L0 形态索引。Memora 支持答案级当前/过时标准，但缺少编程 scope。

MemOps 提供 403 对实例、2,558 个操作和 2,006 个带显式 target 的纵向 probe，用于 oracle 状态管理诊断。LongMemEval-V2 修订版 2cc8c540 提供 200 个选定 small-tier 问题和 1,870 条文本轨迹，用于状态变化、过程和压缩实验。数据读取器实现可替换的任务、事件、来源和指标接口；主策略代码不依赖单一公开数据 schema。

5.2 指标与聚合

对一个已经裁判的答案，MPA 衡量应保留有效事实，FAA 衡量是否避开无效事实。遵循 Memora，本文计算

$$\text{FAMA}_a = \max(0, \text{MPA}_a - \lambda_a(1 - \text{FAA}_a)), \quad \lambda_a = \frac{N_{f,a}}{N_{p,a} + N_{f,a}}.$$

聚合顺序显式固定：首先为每个裁判答案计算 MPA、FAA 和 FAMA；随后对每个问题-arm 的 MiniMax-reader/DeepSeek-judge 与 DeepSeek-reader/MiniMax-judge 单元求均值；最后对冻结问题总体取算术平均。本文不会先分别汇总总体 MPA 与 FAA，再应用非线性 FAMA 公式。

直接证据代理要求当前 session 来源与归一化值同时出现，并对过时暴露施加惩罚。该代理确定、低成本，却无法判断答案是在肯定、否定还是仅叙述旧值。所有主要区间均使用固定种子的成对 persona 聚类 bootstrap。

5.3 模型评测

MiniMax-M3 和 DeepSeek-V4-Flash [7, 2] 是当前 reader 与 judge。条件面板中的每个答案只生成一次并记录两个 judge；主要估计排除自评。D16 使用更严格的分配：每个 MiniMax 答案只由 DeepSeek 裁判，每个 DeepSeek 答案只由 MiniMax 裁判。推理模式关闭，准确模型 ID、官方端点、采样、重试语义和不清晰 verdict 处理均被冻结。模型裁判之间的一致不等于人工正确。

5.4 时间顺序与数据使用

原始 50 题面板以可观察的 Base 失败为条件：192 个季度含遗忘标准的问题中，有 61 个暴露过时 Base Top-5 值，再按种子哈希为每个 persona 选择 5 个问题。面板包含 43 个推荐问题和 7 个记忆问题，用于估计过时暴露条件下的机制效果，不估计总体影响。

D16 使用两个早期 50 题答案面板均未消费的其余 200 个季度问题。它对这些剩余问题进行普查，不以 arm 结果或 Base 过时暴露为条件。然而，季度 Memora 已在早期代理开发中被观察，因此 D16 不是全新的外部数据集留出。其目标是进行广覆盖稳健性和策略因素因果比较。

5.5 实现与调用规模

生命周期 benchmark 包含 54 个版本化 protocol JSON、251 个 TypeScript 源文件/测试文件（其中 50 个测试文件），以及机器可读的原始、摘要、决策、准入和独立验证产物。排除旧版 GPT-4o-mini 次级实验，并避免重复计算字节等价复用单元后，当前 MiniMax/DeepSeek 实验完成 2,456 次 reader 调用和 3,018 次 judge 调用，共 5,474 次。D16 单独消耗 2,805,144 个 API token。

6 D1-D15 研究计划：假设、实验与决策

D1-D15 构成一组有界因果检验。每个方向只改变一个策略组件或辅助表示，在评分前冻结数据边界和门槛，并将失败结果保留在研究账本中。开发证据可以提出下一方向；只有验证或未触碰测试证据能够形成确认。下文按研究机制组织这些方向。

6.1 D1-D4：失效处理与预算约束上下文

D1：过时值屏蔽。 **假设。**重定向后的 V1 上下文仍可能引用失效值；仅遮蔽该值应能减少答案污染，同时保留候选身份和检索顺序。**实验。**D1 保持 V1 的 item id、顺序、条数和答案协议不变，只改变冻结答案面板中的过时值渲染。**结果。**上下文过时值暴露率由 74% 降至 8%，FAA 上升，但 MPA 下降 2.02 个百分点且置信区间为负。**决策。**因答案安全问题拒绝。被移除的片段经常同时承担实体锚点作用，而后继与问题的绑定依赖该锚点。

D2：查询风险路由。 **假设。**只需要当前值的查询可能受益于屏蔽，需要前驱作为锚点的查询则可能受损；使用查询时可观测特征的路由器可在 V1 和 D1 之间选择。**实验。**使用交叉拟合的表面特征规则，任何问题都不会由在该问题上拟合的规则进行评估。所选 V1 或屏蔽上下文随后进入不变的答案协议。**结果。**FAA 提高 2.83 个百分点，MPA 下降 1.15 个百分点，DeepSeek-reader 的 FAMA 方向仍为负。**决策。**拒绝。现有词法特征不能以足够可靠性识别锚点依赖。

D3：删除空位回填。 **假设。**delete tombstone 可能占据 Top-k 槽位而不提供答案证据；继续扫描同一基座候选池应能恢复有效 item。**实验。**D3 只改变空位处理，不扩展到冻结基座候选池之外，并保持原返回条数上限。**结果。**直接代理提高 1.40 个百分点，低于预注册的 2 个百分点门槛；token 增加 2.89%。**决策。**在答案生成前因效果幅度和成本拒绝。

D4：有效状态装箱。 **假设。**固定 item 数量不能约束上下文长度；联合控制 item 和 token 可在 V1 token 上限内提高有效状态密度。**实验。**在开发反馈上评估 9 个条数-预算组合，选择一个策略，再冻结参数并运行新的 50 题答案面板。**结果。**FAMA 提高 1.16 个百分点，token 降低 3.27%，但 95% 区间为 $[-0.14, +2.90]$ 个百分点。**决策。**记录为近失结果，并因不确定性拒绝。

6.2 D5-D6：显式状态与现行策略保护

D5：目标键控状态投影。 假设。使用失效值子串匹配存在实体歧义；显式 MemOps operation target 应形成更准确的当前状态视图。**实验。**在分离的开发、验证和未触碰测试分区上，按 target key 投影 Update、Delete 和 No-op 操作，并与值链接的 V1 状态比较。**结果。**未触碰测试 state-FAMA 提高 6.46 个百分点，区间为 $[-2.40, +15.10]$ ；4 个 Update 问题受损。检查发现，独立装箱的 target 视图可能遗漏 V1 已恢复的当前或未知证据。**决策。**拒绝独立状态投影。

D6：现行策略支配守卫。 假设。只有在保留现行策略的每个当前或未知 item、且不引入过时 item 时，目标键控状态才应被准入。**实验。**增加支配守卫；候选违反集合级不变量时返回 V1。该规则在已消费的 D5 数据上审计，因为它是在观察 D5 失败后提出的。**结果。**State-FAMA 提高 6.11 个百分点，28 个问题改善，0 个问题受损。**决策。**仅保留为后验可行性证据；仍需新的确认集。

6.3 D7-D11：状态变化与过程记忆

D7：状态变化差分。 假设。原始浏览器或工具状态包含大量重复静态内容；pre/action/post 差分单元应更直接地暴露任务相关变化。**实验。**将 accessibility-tree 状态变化与 Base FTS5 并行索引，在开发集选择固定检索策略后进行验证。**结果。**开发集直接支持度提高 8.13 个百分点，验证集反转为 -6.67 个百分点；token 增加 3.50%。**决策。**因迁移失败拒绝。

D8：带空动作的效用学习。 假设。D7 混合了有用和无关变化；经验效用门与显式 no-change 动作可以抑制不安全替换。**实验。**从已消费的状态变化结果估计效用，并在未触碰测试数据上运行冻结门控。**结果。**token 下降 2.92%，但每个可评分问题的直接支持度均与 Base 完全相同，没有问题改善。**决策。**作为质量策略拒绝；将空动作结果保留为压缩线索。

D9：结果门控过程记忆。 假设。成功轨迹应产生可复用过程，失败轨迹应在写入时降低权重。**实验。**由整轨迹结果控制绑定安全的过程 capsule 准入；在为验证冻结所选策略前，先评估不读取结果的消融。**结果。**开发集中结果无关消融更优，冻结候选在验证集上损失 11.11 个直接支持百分点。**决策。**拒绝。终局结果对步骤级信用过粗，因为失败轨迹可能包含有用前缀，成功轨迹也可能包含绕路。

D10：局部验证替换。 假设。局部状态进展提供比终局结果更细的信用，将替换限制在同轨迹 Base item 应能控制污染。**实验。**D10 构造局部验证的动作骨架，并在固定预算内只替换合格的同轨迹 item。**结果。**token 下降 33.55%，但包含正确值 *priority* 的关键 StaticText 语义叶子被删除；局部反馈没有提高支持度。**决策。**因证据安全拒绝。仅保留动作结构不能保留正文、代码或诊断证据。

D11：证据保真替换。 假设。只有每个有界语义叶子、来源、顺序关系和无关 Base item 均被保留时，压缩才可准入。**实验。**在一个同轨迹 capsule 替换 Base item 之前，由证书检查这些不变量；证书、容量、超时或完整性任一失败时返回精确 Base。校验值冻结测试包含 30 个问题，其中 12 个可直接计算答案原子支持度。**结果。**平均 token 下降 20.84%；12 个直接问题全部与 Base 相同，0 改善、0 受损。**决策。**在冻结的质量改善目标下拒绝，并保留为效率结果。第 11 节报告完整成本证据。

6.4 D12-D13：证据可达性与残差修复

D12：同轨迹外部扩展。 假设。D11 只压缩 Base 已经可访问的证据；从同轨迹增加最多一个 Base 缺失 item 可能恢复缺失答案原子。**实验。**固定 Base 预算和索引保持不变。规则在同轨迹 Top-40 中最多加入一个候选，不读取答案，并且失败后不尝试第二候选。**结果。**开发集直接支持度相对 Base 下降 3.33 个百分点，5 个问题受损。**决策。**在开发阶段停止并拒绝扩展。

D13：残差反馈补丁。 假设。D12 应限制在匹配既往缺失证据签名的问题上。**实验。**由已消费失败定义冻结签名；不匹配查询精确返回 Base。**结果。**23 个可直接评分问题全部与 Base 相同，token 增加 0.99%。**决策。**因无质量效果拒绝。规则触发没有创造新的答案可达证据。

6.5 D14-D15: 低覆盖条件下的前提反驳

D14: 前提反驳检索。 假设。部分失败来自查询预设过时事实；检索直接反驳证据应阻止该前提进入答案。**实验。**在 33 个 premise 问题和 25 个控制问题上评估确定性触发器，只对发生上下文变化的问题调用 reader。**结果。**2 个 premise 问题触发，控制问题无触发，但 4 个变化 reader 单元均与 Base 相同。**决策。**因低覆盖和无答案效果拒绝。

D15: 类型化反驳合同。 假设。显式 *premise*、*refutation*、*witness* 和 *scope* 字段应使有效反证更易被 reader 使用。**实验。**首先在两个已消费 D14 触发问题上审计 renderer，随后冻结。在新的验证集中，先测量 23 个 premise 和 20 个控制问题的触发覆盖；只有覆盖通过后才授权答案调用。**结果。**4 个已消费设计 reader 对中有 3 个改善，但 43 个验证上下文均为精确 Base no-op，因为触发器 0 次触发。**决策。**因验证覆盖率为零拒绝。提前停止由协议决定，验证阶段没有执行答案调用。

6.6 跨方向综合

表 7 记录证据阶段和最终解释。后续方向不会自动继承早期开发增益的确认地位。

ID	改变量与证据阶段	主要结果	决策
D1	过时片段渲染；答案面板	暴露率 74% 到 8%；MPA -2.02 个百分点且区间为负。	安全拒绝
D2	交叉拟合 V1/屏蔽路由；答案面板	FAA $+2.83$ 、MPA -1.15 个百分点；一个 reader 的 FAMA 为负。	拒绝
D3	删除空位回填；直接门槛	代理 $+1.40$ 个百分点，低于门槛；token $+2.89\%$ 。	拒绝
D4	条数-token 装箱；新答案面板	FAMA $+1.16$ 个百分点，token -3.27% ，区间跨零。	近失
D5	目标键控投影；未触碰测试	State-FAMA $+6.46$ 个百分点；4 个 Update 受损。	测试拒绝
D6	现行策略支配守卫；已消费审计	State-FAMA $+6.11$ 个百分点；28 改善，0 受损。	仅后验
D7	状态变化索引；验证	开发 $+8.13$ 个百分点；验证 -6.67 个百分点。	迁移拒绝
D8	效用/空动作；未触碰测试	token -2.92% ；支持度完全不变。	质量拒绝
D9	结果门控过程；验证	结果无关开发消融更优；验证 -11.11 个百分点。	拒绝
D10	局部进展骨架；验证	token -33.55% ，但关键正文证据丢失。	安全拒绝
D11	语义叶子证书 capsule；未触碰测试	token -20.84% ；12 个直接问题均与 Base 相同。	仅效率
D12	一个同轨迹外部叶子；开发	支持度 -3.33 个百分点，5 个问题受损。	开发拒绝
D13	失败签名残差补丁；开发	23 个直接问题与 Base 相同；token $+0.99\%$ 。	无效果拒绝
D14	前提反驳触发；premise/control 面板	33 个中触发 2 个，控制为 0；变化答案与 Base 相同。	拒绝
D15	类型化合同；新覆盖验证	已消费设计改善 3/4 对；验证触发 0/23。	覆盖拒绝

表 7: D1-D15 证据账本。各结果保留原始的开发、验证、测试或后验状态。

综合证据进一步缩小了机制范围。表面失效处理必须保留实体锚点；item 数量与 token 预算需要分别控制；显式状态应在现行策略保真不变量下组合；轨迹结果不能提供充分的步骤级信用；压缩需要语义叶子证书；证据扩展需要答案可达性检验；在 renderer 质量发挥作用之前，前提修复首先受到触发覆盖率限制。

7 条件型 V1/V2 答案实验

表 8 报告原始 50 题面板。V1 相对 Base 改善全部主要质量指标。V2 的 MPA 略高于 V1，但 FAA 下降 4.08 个百分点，注入 token 增加 37.53%。其相对 V1 的 FAMA 差值为负，且区间跨零。因此，晋升门槛保留 V1。

指标	Base	V1	V2	V1 -Base [95% CI]	V2 -Base [95% CI]	V2 -V1 [95% CI]
MPA	0.3855	0.4342	0.4461	$+0.0487$ [0.0196, 0.0928]	$+0.0606$ [0.0216, 0.1090]	$+0.0119$ [-0.0039, 0.0276]
FAA	0.8531	0.9369	0.8961	$+0.0838$ [0.0599, 0.1067]	$+0.0431$ [0.0029, 0.0848]	-0.0408 [-0.0762, -0.0064]
FAMA	0.3195	0.4004	0.3961	$+0.0809$ [0.0517, 0.1259]	$+0.0766$ [0.0441, 0.1141]	-0.0043 [-0.0206, 0.0109]
标准准确率	0.7040	0.7606	0.7382	$+0.0566$ [0.0385, 0.0758]	$+0.0342$ [0.0118, 0.0604]	-0.0224 [-0.0424, -0.0042]
平均 token	144.52	146.76	201.84	$+1.55\%$	$+39.66\%$	$+37.53\%$

表 8: 条件面板：50 个 Base 过时暴露问题，其中 43 个推荐问题、7 个记忆问题。

该条件实验表明，当上下文中确实存在过时证据时，纠错链重定向可以改善答案。由于样本选择要求出现 Base 失败，该结果不能估计无条件部署效果。

8 D16: 广覆盖基线与单因素消融

8.1 设计与完整性

D16 在 10 个 persona 上冻结 200 个问题：100 个推理问题、62 个记忆问题和 38 个推荐问题；92 个问题含遗忘标准，只有 6 个问题出现 Base 过时暴露。13 个 arm 包含 Base、V1、4 个简单基线、6 个独立 V2 因素和完整 V2：

- tombstone refill 与 latest-write-wins；
- 纯 recency Top-5 与显式 superseded/history 渲染；
- V1 分别增加两跳、一个附加槽位、两个附加槽位、阈值.91、阈值.96 或历史汇总保护；
- 完整 V2。

该设计包含 2,600 个问题-arm 上下文。同一问题中 message 数组字节完全相同的 reader 提示只生成并裁判一次，随后复用。每个 reader 因此只有 947 个唯一提示，共执行 1,894 次 reader 调用和 1,894 次交叉 judge 调用，而非 5,200 次 reader 调用。实验中重试、reader/judge 模型不匹配和自评次数均为 0。两个不清晰 verdict 按错误处理。独立解析器重新评分全部 1,894 条原始评测，重建 13 个 arm 汇总和 12 个相对 V1 的比较，差异为 0。

8.2 全量结果

表 9 给出广覆盖结果。没有候选同时通过所有冻结的效果幅度、不确定性、FAA/MPA、成本和完整性检查。

Arm	MPA	FAA	FAMA	FAMA-V1 [95% CI]	token	token Δ	决策
Base	0.1500	0.9780	0.1428	-0.0142 [-0.0308,0.00005]	134.19	+0.77%	基线
V1	0.1620	0.9881	0.1570	-	133.16	-	现行策略
Tombstone refill	0.1601	0.9838	0.1533	-0.0037 [-0.0149,0.0070]	133.39	+0.17%	拒绝
Latest-write-wins	0.1598	0.9880	0.1543	-0.0027 [-0.0094,0.0039]	135.03	+1.40%	拒绝
Recency Top-5	0.1453	0.9821	0.1393	-0.0176 [-0.0403,0.0057]	118.97	-10.66%	质量拒绝
Superseded 渲染	0.1559	0.9849	0.1497	-0.0073 [-0.0230,0.0080]	146.99	+10.39%	拒绝
V1 + H2	0.1588	0.9879	0.1536	-0.0034 [-0.0086,0]	134.42	+0.95%	拒绝
V1 + 1 槽	0.1670	0.9862	0.1609	+0.0039 [-0.0068,0.0144]	148.66	+11.64%	成本/CI 拒绝
V1 + 2 槽	0.1740	0.9831	0.1663	+0.0093 [-0.0027,0.0227]	160.04	+20.19%	成本/CI 拒绝
V1 $\tau = .91$	0.1616	0.9889	0.1565	-0.0004 [-0.0013,0]	133.23	+0.06%	拒绝
V1 $\tau = .96$	0.1656	0.9881	0.1600	+0.0030 [-0.0010,0.0083]	133.56	+0.30%	近失
V1 + 历史汇总保护	0.1595	0.9881	0.1545	-0.0025 [-0.0100,0.0050]	134.14	+0.74%	拒绝
V2	0.1680	0.9831	0.1591	+0.0021 [-0.0073,0.0108]	147.99	+11.14%	拒绝

表 9: D16 全量交叉答案结果。token 差值均相对 V1。

附加槽位揭示了核心权衡。更多上下文提高 MPA 和 FAMA 点估计，但降低 FAA、增加 11.6–20.2% token，且不能以置信度优势超过 V1。阈值.96 是成本最低的正向近失方案；其相对 V1 的 +0.30 FAMA 百分点区间跨零。两跳和历史汇总保护在该总体上均略有伤害。简单基线没有支配生命周期现行策略。

8.3 V1 的异质效果

全量 V1-Base FAMA 差值为 +0.01416，区间为 [-0.000046, +0.03082]。FAA 提高 +0.01007 且区间为正，但主要 FAMA 不确定性规则未通过。表 10 解释条件面板与广覆盖面板的差异。

切片	<i>n</i>	FAMA Δ [95% CI]	MPA Δ [95% CI]	解释
全量	200	+0.0142 [-0.00005,0.0308]	+0.0120 [-0.0031,0.0285]	正向，不确定
含遗忘标准	92	+0.0296 [0.0074,0.0549]	+0.0262 [0.0044,0.0517]	确认正向切片
Base 过时暴露	6	+0.3919 [0.2897,0.4694]	+0.3111 [0.1400,0.4286]	大幅度，仅 5 个 cluster
推荐任务	38	+0.0768 [0.0203,0.1395]	+0.0751	强正向任务切片
记忆任务	62	-0.0095 [-0.0247,0.0029]	-0.0153 [-0.0319,-0.0029]	MPA 伤害信号
推理任务	100	+0.0050 [-0.0100,0.0200]	-	未确认效果

表 10: D16 中 V1 相对 Base 的冻结描述性切片。分组结果不覆盖主要晋升门槛。

原始 50 题面板集中采样生命周期纠错最可能发挥作用的场景。D16 没有否定该机制结果，而是限制了其部署解释。未来选择性路由器必须使用运行时可观测风险特征，并在新数据上确认；benchmark 任务标签不能直接复制为生产路由。

9 D17: 立场能否修复代理指标?

公开的直接代理对归一化过时值出现施加惩罚，但不区分肯定、否定或历史叙述。D17 冻结一个基于英语 marker 的立场代理：肯定、否定和历史提及分别使用 1.0、0.25 和 0.1 的暴露权重。在确定权重时不读取答案结果，并据此排序全部 13 个 D16 策略。

与答案 FAMA 的 Kendall τ_b 由 0.5290 提高至 0.5385，增量 0.0094，低于冻结的 0.10 要求。与 MPA 的相关性由 0.4774 提高至 0.4872，与 FAA 的相关性由 0 提高至 0.0129。相对 V1 的成对方向一致率仍为 8/12。两个代理都正确预测了观测到的 V2-V1 FAMA 方向，但总体门槛失败。

该负结果排除了一个直接捷径。简单立场 marker 可以改善少数描述，却不能替代语义评测或答案级评测。学习型代理需要人工标定，同时仍需保留下游晋升边界。

10 D18: 纯文本纠错构链

10.1 协议

D18 直接处理 V1 中的准 oracle 边构造问题。运行时输入限制为 session id、persona、共享对话文本，以及同 persona 最多 512 个更早共享单元。禁止读取 session type、operation、operation details、评测问题和证据标签。冻结的确定性检测器识别显式删除、no-longer、完成、used-to/now、from/to、偏好变化和替换 cue。加权词法链接器最多输出 3 个前驱 id；没有历史单元通过阈值时拒答。

季度历史从周级/月级前缀中去重，并按 persona 划分：4 个开发、3 个验证和 3 个测试 persona。公开 operation 只在预测完成后挂接，用于定义失效 session、事件类型、过时值和前驱单元。协议不授权答案模型调用。

10.2 结果

测试分区包含 5,954 个 session 和 1,223 个 gold 失效 session。表 11 比较 literal remove/delete 基线、仅 cue 分类和高置信链接预测。

指标	仅 remove/delete	仅 cue	高置信链接
事件精确率	1.0000	0.9781	0.9789
事件召回率	0.1562	0.8029	0.7964
事件 F1	0.2702	0.8819	0.8783
类型准确率	1.0000	0.8228	0.8234
预测前驱链接数	0	0	2,823
链接精确率	—	—	0.2005
链接召回率	—	—	0.1618
至少一条正确链接率	—	—	0.4538
检测器 p95	—	—	5.51 ms

表 11: D18 persona 隔离测试结果。至少一条正确链接率以真实性且发生链接的 session 为分母。

事件精确率、事件召回率、链接召回率、时延和禁止字段读取检查通过；链接精确率、至少一条正确链接率和类型准确率失败。验证集方向一致，其链接精确率为 19.80%，至少一条正确链接率为 45.74%。

核心错误来自实体与状态歧义。一个带 cue 的消息可能与许多历史单元共享 budget、project 或 music 等词，却不指向同一字段或状态。检测发生了纠错显著易于判断它具体使什么内容失效。因此，本文将全部 V1 答案结果归类为 oracle 管理证据，并拒绝端到端构链结论。

11 D11: 独立效率证据

D11 只有在保留每个已抽取语义叶子、来源顺序、来源、无关 Base item、item 数量和 token 证书时，才允许用一个有界 capsule 替换选定的同轨迹 Base item；否则返回精确 Base。校验值冻结的 LongMemEval-V2 测试包含 30 个问题，其中 12 个可以直接计算答案原子支持度。

在全部 30 个问题上，D11 接受 19 次替换，将平均注入 token 从 2,796.8 降至 2,213.9，下降 20.84%。

12 个直接问题中, Base 与 D11 均为 0.2083; 0 改善、12 相同、0 受损。查询 p95 由 227.5 ms 变为 231.1 ms; 选择 p95 为 3.08 ms。token、覆盖、来源、容量和强制回退违规均为 0。

冻结目标要求质量改善, 因此 D11 被正确拒绝质量晋升, 且未准入答案生成。直接支持度相同不等于答案级非劣。本文只将其保留为已测量的支持度-成本 Pareto 点, 并提出一个带答案非劣界的独立效率协议。

12 讨论

12.1 已经获得支持的机制

当基座上下文包含失效记忆时, 纠错链重定向能够改善下游答案。该机制固定预算、有界、可审计、可关闭, 并兼容现有检索器。更一般的研究结果是晋升架构: V2、D1、D4 和 D17 分别说明, 合理或正向的直接信号仍可能在答案、不确定性或成本边界上失败。

广覆盖数据支持风险-覆盖策略, 不支持无条件生命周期改写。含遗忘标准和推荐切片获得收益, 记忆任务的 MPA 可能受损。该结果尚未定义可部署路由器: 分组标签只用于诊断, 路由假设形成于观察 D16 结果之后, 因此需要新数据确认。

12.2 未通过验证的机制

更多槽位在召回、过时暴露和成本之间形成权衡; 更多跳数不会自动产生收益; recency 节省 token 但损失质量; 显式渲染 superseded 事实增加成本且不占优。整轨迹结果标签对过程记忆过粗; 保留动作结构但丢失语义叶子不安全; 类型化反驳在触发覆盖率为零时无法迁移; 英语立场 marker 不足以使代理对齐; 词法事件到前驱的链接即使具有较强事件分类, 也仍不安全。

12.3 向编程会话迁移

可迁移接口包括事件、scope、候选、来源、反馈、指标和报告适配器。内部编程适配器应在如下复合键上表示有效性:

(repo, branch, base commit, worktree, environment, task phase, file/symbol, claim type).

每条声明应处于 active、superseded 或 unknown 状态。scope 未知时必须拒答, 不能直接执行失效。

有潜力但尚未验证的扩展包括: 可执行 witness (test command、exit code、commit、file hash、environment); 由 Git diff/rename/revert 和测试状态变化提出的隐式候选; 分支或 commit 变化后的 memory rebase; 以及检查注入记忆是否改变计划、编辑、测试或 patch 的污染差分评测。公开或内部 RepoDriftBench 适配器可以公开这些字段, 而无需改变生命周期控制器。这些内容属于设计, 不是本文实验结果。

12.4 成本与置信度

D16 展示了一个实用的双保真 workflow。精确上下文指标和提示复用以较低成本淘汰大量候选; 答案调用仅用于冻结 arm 和唯一提示。这使 D16 所需 reader 调用减少 63.6%。然而, 两个模型裁判可能共享偏差。下一项证据优先级应是人工标定子集, 而非继续扩大代理搜索。

13 局限

第一, Memora 属于个性化对话, 不是软件工程数据, 缺少仓库、分支、commit、worktree、环境、组件和测试 scope。第二, 全部季度问题都曾在早期代理分析中出现; D16 问题未被答案实验消费, 但不属于全新数据集留出。第三, 原始 50 题面板有意以过时暴露为条件, 不能估计总流量影响。第四, 模型裁判一致不能建立人工正确性。第五, D11 只有 12 个直接支持度问题, 且没有生成答案非劣实验。第六, D18 使用确定性英语 cue 和 operation 派生评分, 不能覆盖隐式代码状态失效。第七, 精确 Base 回退保护可用性, 不保护语义正确性。最后, D1-D18 涉及连续科学探索。本文保留协议时间顺序和负结果, 但只有新的外部或内部数据才能支持部署结论。

14 可复现性与产物

每项主要实验均记录数据集修订版或清单、协议版本、选择或普查规则、种子、模型配置、原始 JSONL、摘要、决策、成本、回退检查和声明边界。D16 提供原始评测 SHA-256、独立重建和零差异报告。D18 提供冻结 persona 划分、禁止运行时字段、逐 session 预测和产物 hash。结构化方向注册表区分通过、拒绝、近失、后验和仅效率结果。

实现保持旁路形式。关闭旁路、破坏结构、强制超时、超出容量或遇到循环时，系统返回原始基座调用。替换数据适配器无需重写策略与报告逻辑。

15 结论

本文将记忆自优化定义为受控生命周期策略演化。固定预算纠错链管理在过时 **Base** 证据存在时产生显著增益，并在广覆盖含遗忘标准问题上获得确认收益，但现有证据不支持其作为无条件默认策略。更丰富的代理选择策略、简单时序基线、独立因素和立场感知代理均未通过冻结晋升。纯文本纠错事件检测准确，自动前驱链接不准确。证据保真压缩降低了已测量上下文成本，仍需答案级非劣验证。

最终策略保持保守：保留 **Base**，只在高置信、scope 明确的证据和经过新数据验证的风险门槛下启用生命周期管理；质量与效率使用不同晋升轨；链接歧义时拒答；保持精确运行回退。下一项核心研究问题是面向仓库状态、带 witness 的 scope 化失效，而非扩大 Top- k 。

参考文献

- [1] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready ai agents with scalable long-term memory. *arXiv preprint arXiv:2504.19413*, 2025.
- [2] DeepSeek. DeepSeek-V4 Preview: Entering the era of affordable million-token context. <https://deepseek.com/en/news/v4-p-review/>, 2026. Accessed 2026-08-21.
- [3] Shuzheng Gao, Wenhao Zeng, Zhaojian Yu, Jianqiao Wangni, Chaozheng Wang, Kai Cai, Shilin He, and Michael R. Lyu. SWE-MeM: Learning adaptive memory management for long-horizon coding agents. *arXiv preprint arXiv:2606.28434*, 2026.
- [4] Yuanzhe Hu, Yu Wang, and Julian McAuley. Evaluating memory in llm agents via incremental multi-turn interactions. *arXiv preprint arXiv:2507.05257*, 2026.
- [5] Enze Ma, Yufan Zhou, Wei-Chieh Huang, Jie Yang, Huanhuan Ma, Zixuan Wang, Chengze Li, Chunyu Miao, Philip S. Yu, and Zhen Wang. MEMPROBE: Probing long-term agent memory via hidden user-state recovery. *arXiv preprint arXiv:2606.24595*, 2026.
- [6] Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of llm agents. *arXiv preprint arXiv:2402.17753*, 2024.
- [7] MiniMax. MiniMax M3: Frontier coding, 1m context, native multimodality. <https://www.minimax.io/blog/minimax-m3>, 2026. Accessed 2026-08-21.
- [8] Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. Memgpt: Towards llms as operating systems. *arXiv preprint arXiv:2310.08560*, 2023.
- [9] Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A temporal knowledge graph architecture for agent memory. *arXiv preprint arXiv:2501.13956*, 2025.
- [10] Kangning Shen, Jingyuan Zhang, Chenxi Sun, Wencong Zeng, and Yang Yue. Structurally aligned subtask-level memory for software engineering agents. *arXiv preprint arXiv:2602.21611*, 2026.
- [11] Noah Shinn, Federico Cassano, Edward Berman, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. *arXiv preprint arXiv:2303.11366*, 2023.
- [12] TencentCloud. Tencentdb agent memory: Memorycore. <https://github.com/TencentCloud/TencentDB-Agent-Memory>, 2026. MemoryCore at tag v2.0.0-beta.1.
- [13] Md Nayem Uddin, Kumar Shubham, Eduardo Blanco, Chitta Baral, and Gengyu Wang. From recall to forgetting: Benchmarking long-term memory for personalized agents. *arXiv preprint arXiv:2604.20006*, 2026.
- [14] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. Longmemeval: Benchmarking chat assistants on long-term interactive memory. *arXiv preprint arXiv:2410.10813*, 2024.
- [15] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. A-mem: Agentic memory for llm agents. *arXiv preprint arXiv:2502.12110*, 2025.
- [16] Sikuan Yan, Xiufeng Yang, Zuchao Huang, Ercong Nie, Zifeng Ding, Zonggen Li, Xiaowen Ma, Hinrich Schütze, Volker Tresp, and Yunpu Ma. Memory-r1: Enhancing large language model agents to manage and utilize memories via reinforcement learning. *arXiv preprint arXiv:2508.19828*, 2025.
- [17] Shu Yang, Junchao Wu, Derek F. Wong, and Di Wang. Selfmem: Self-optimizing memory for ai agents. *arXiv preprint arXiv:2607.03726*, 2026.
- [18] Jianing Yin and Tan Tang. Defermem: Query-time evidence distillation via reinforcement learning for long-term memory qa. *arXiv preprint arXiv:2605.22411*, 2026.
- [19] Zep AI. Graphiti: Build temporal context graphs for ai agents. <https://github.com/getzep/graphiti>, 2026. Open-source temporal context graph engine; accessed 2026-08-24.
- [20] Xuhui Zhou, Valerie Chen, Zora Zhiruo Wang, Graham Neubig, Maarten Sap, and Xingyao Wang. TOM-SWE: User mental modeling for software engineering agents. *arXiv preprint arXiv:2510.21903*, 2026.